

Сравнение подходов к обучению нейронных сетей для однопиксельной визуализации со сжатыми измерениями

Халиков Р.Ф.^{1,2}, Хасанов И.Ш.¹

¹ Научно-технологический центр уникального приборостроения РАН, Москва, Россия

² МГТУ им. Баумана, Москва, Россия

SPIN-коды: 6049-6419

ruslan.arkwen@gmail.com

Исследование посвящено сравнительному анализу методов обучения нейронных сетей для однопиксельной визуализации со сжатыми измерениями, при которой изображение восстанавливается из ограниченного числа сигналов приёмника. Актуальность темы обусловлена возможностью применения в спектральных диапазонах, где двумерные матричные приёмники экономически или технологически недоступны (в частности, в терагерцевом диапазоне), а также в условиях низкой освещённости или высокой радиационной нагрузки. Уменьшение количества измерений ускоряет цикл «измерение → решение», что особенно важно для систем контроля. Кроме того, снижение дозовой нагрузки повышает безопасность медицинских исследований *in vivo*. Современные исследования показывают, что задачу однопиксельной визуализации можно сформулировать как задачу прямой классификации в сжатом пространстве измерений, при которой нейросеть распознаёт класс объекта без необходимости полной реконструкции изображения. В настоящей работе проведена оценка эффективности различных подходов к обучению таких сетей при разных уровнях сжатия и ограниченном наборе классов с целью обеспечения надёжного распознавания при минимальном числе измерений. Полученные выводы закладывают основу для создания нового поколения терагерцевых сканеров с использованием искусственного интеллекта, предназначенных для медицины, неразрушающего контроля и систем безопасности.

Ключевые слова: однопиксельная визуализация, compressed sensing, нейронные сети

Введение

Сжимающие измерения (compressed sensing, CS) — математическая парадигма, согласно которой s -разреженный или иным образом сжимаемый сигнал можно точно восстановить из M линейных проекций, существенно меньшего полной размерности N . CS дополняет классическую теорему Котельникова–Найквиста–Шеннона, утверждая, что для разреженных сигналов требование минимальной частоты дискретизации может быть ослаблено. Такая возможность радикально снижает требования к приёмникам и даёт прямой выигрыш по времени, энергетическим затратам и радиационной дозе. Однопиксельная визуализация с пространственными модуляторами света [2] естественным образом сочетает принципы CS и востребована там, где двумерные матричные камеры экономически или технологически недоступны: терагерцевый диапазон [3], гиперспектральная съёмка, среда с высокой радиационной нагрузкой и т. д. Современные исследования показывают, что во многих прикладных задачах (неразрушающий контроль, биомедицина, системы безопасности) зачастую достаточно сразу переходить к классификации или обнаружению объектов непосредственно в пространстве измерений, минуя трудоёмкую фазу точной реконструкции изображения [4].

Моделирование

Для исследования работы нейросетей совместно с алгоритмом CS используем классический набор изображений (датасет) MNIST, который представляет собой набор образцов рукописного написания цифр, являющихся двумерными изображениями 32×32 пикселя, принадлежащих одному из $K = 10$ классов. В методе однопиксельной визуализации приёмник регистрирует скалярные величины:

$$y = Ax, x \in R^M, M < N, \quad (1)$$

где A — маска Адамара. Задачей является по вектору y определить класс объекта $c \in \{0, \dots, 9\}$ с максимальной точностью при минимальном M (числе измерений, количестве паттернов). CS обеспечивает реконструкцию при соблюдении условия малости взаимной зависимости (некогерентности μ) между строками измерительной матрицы A и разреженным базисом Ψ [5]:

$$\mu(A, \Psi) = \sqrt{N} \frac{|\langle a_i, \psi_j \rangle|}{\|a_i\|_2}. \quad (2)$$

Для задачи классификации восстановленного алгоритмом CS изображения использована трехслойная полносвязная нейронная сеть (многослойный перцептрон, MLP). Обучение велось по кросс-энтропийному критерию Adam-оптимизатором (по 3 эпохи) с помощью PyTorch и CUDA на видеокарте с GPU NVIDIA RTX 3050. Время обучения одной нейросети составляло ~ 7 ч. Время инференса изображения 0.3 с.




Рис. 1. а) пример изображения рукописной цифры 4 из датасета MNIST; б) графики корреляции восстановленного изображения алгоритмом CS при различном числе измерений в случае: случайного порядка паттернов и упорядоченных по убыванию некогерентности μ

На рисунке 1(а) показан пример исходного изображения цифры «4» из MNIST; рисунок 1(б) демонстрирует, как корреляция между исходным и восстановленным изображением зависит от количества и порядка использованных паттернов на основе матриц Адамара. Видно, что упорядочение паттернов по уменьшению коэффициента некогерентности μ обеспечивает более плавный и предсказуемый линейный рост точности реконструкции по мере увеличения числа измерений M .




Рис. 2. Сравнение точности нейросетей при классификации изображений, восстановленных алгоритмом CS при различном числе измерений, для моделей, обученных на исходных изображениях (Модель 0), на зашумленных изображениях, обученных на изображения восстановленных алгоритмом CS при различном числе измерений M (200,300,600).

На рис. 2 показано, что нейросети, обученные на изображениях, восстановленных алгоритмом CS, превосходят модели обученные на исходных и искусственно зашумленных «пересвеченных»/размытых изображениях (см. рис 3(а) и 3(д)). Также отметим, что уже при $M = 200$ достигается точность (accuracy) 90 %, а разница с нейросетями, обученными на изображениях с большим числом $M = 300$ и $M=600$ не превышает 5%. Что позволяет существенно экономить время на создание обучающей выборки для обучения таких нейросетей.




Рис. 3. а) исходное изображение рукописной цифры 4 из MNIST; восстановленное алгоритмом CS изображение (а) при M измерений: б) $M=200$; в) $M=300$; г) $M=600$; д)

изображение (а), размытое гауссовым фильтром ($\sigma = 0,15$) с гауссовым шумом (с единичным средним и дисперсией) с обрезкой значений выше 1 (перезэкспонирование)

Отметим, что визуально реконструируемые изображения при $M = 200$ малоинформативны для человека (см. рис. 3(б)), что подчёркивает преимущество машинной классификации.




Рис.4. График средних вероятностей классификации нейросети (обученной при $M = 200$) для восстановленных алгоритмом CS изображений в зависимости от числа измерений:
а) рукописная цифра «4» (MNIST); б) рукописная буква «g» (EMNIST).

Важным аспектом для практического применения является реакция нейросетей на неизвестные данные. Для проверки были использованы рукописные буквы из набора EMNIST. Для них, как правило максимальная вероятность классификации не превышала 0.5, а определяемые классы не различались более, чем на стандартное отклонение, в отличие от распознавания цифр (см. рис. 4). Это указывает на возможность обнаружения аномалий без необходимости обучения на всех возможных примерах.

Обсуждение

Минимально достаточное число измерений M определяется не визуальным качеством изображения, а разрежённостью пространства значимых признаков, необходимого нейронной сети для уверенной классификации. Для MNIST эта граница эмпирически равна $\approx 20\%$ от полной размерности. Для других датасетов граница может смещаться, что требует дальнейшего исследования (например, Fashion-MNIST, CIFAR-10). Низкая уверенность сети на буквах демонстрирует её потенциал для задач, где важно не пропустить целевые, но редкие объекты (запрещённые к провозу предметы, дефекты, маркеры заболеваний и т.д.) среди множества неизвестных.

Заключение

Проведённый анализ ещё раз подтвердил применимость нейронных сетей для задачи классификации в случае однопиксельной визуализации со сжатыми измерениями (CS). При использовании матриц Адамара достаточно 200 измерений вместо полных 1024, чтобы достичь точности $\approx 94\%$ на датасете MNIST, что позволяет существенно ускорить процесс измерений и диагностики. В дальнейшем планируется: использовать реальные экспериментальные данные приёмника терагерцового диапазона; оптимизировать используемую архитектуру нейросети для динамической реконструкции в зависимости от числа измерений в режиме реального времени. Таким образом, новые парадигмы в методах измерений, такие как CS и однопиксельная визуализация, демонстрируют высокую синергию с нейросетевыми методами. Совместное использование этих подходов способствует созданию нового класса приборов, ориентированных непосредственно на искусственный интеллект, а не на сенсорное восприятие информации человеком.

Список литературы

1. Donoho D.L. Compressed sensing // IEEE Transactions on Information Theory. 2006. Vol. 52, № 4. P. 1289–1306. DOI: 10.1109/TIT.2006.871582
2. Duarte M. F. *et al.* Single-pixel imaging via compressive sampling // IEEE Signal Processing Magazine. 2008. V. 25, № 2. P. 83–91. DOI: 10.1109/MSP.2007.914730.
3. Khasanov I.Sh., Blagova T.V. Optimization of compressive ghost imaging in the terahertz range using correlation-based ranking in optical system transmission // 2024 Intelligent technologies and electronic devices in vehicle and road transport complex (TIRVED). Moscow, Russian Federation: IEEE, 2024. P. 1–5. DOI: 10.1109/TIRVED63561.2024.10769870
4. Fu H., Bian L., Zhang J. Non-imaging single-pixel sensing with optimized binary modulation // Opt. Lett. 2020. Vol. 45, № 11. P. 3111. DOI: 10.1364/OL.395150
5. Граничин О.Н., Павленко Д.В. Рандомизация получения данных и ℓ_1 -оптимизация (опознание со сжатием) // Автоматика и телемеханика. 2010. № 11. С. 3–28.

Comparison of neural-network training approaches for single-pixel imaging with compressed measurements

Khalikov R.F.^{1,2}, Khasanov I.S.¹

¹Scientific and Technological Centre of Unique Instrumentation of RAS, Moscow, Russia

²Bauman State University, Moscow, Russia

ruslan.arkwen@gmail.com

This study presents a comparative analysis of neural-network training methods for single-pixel imaging with compressed measurements, where an image is reconstructed from a limited number of detector signals. The topic is relevant for spectral ranges in which two-dimensional detector arrays are economically or technologically impractical—most notably in the terahertz band—as well as for low-light or high-radiation environments. Reducing the number of measurements shortens the “measurement-to-decision” cycle, which is critical for inspection systems, while lowering the radiation dose improves the safety of in vivo medical studies. Recent research shows

that single-pixel imaging can be reformulated as a direct classification problem in the compressed measurement space, allowing a neural network to recognize an object's class without fully reconstructing the image. The present work evaluates the effectiveness of different training strategies for such networks at various compression levels and with a limited set of classes, aiming to achieve reliable recognition with the minimum number of measurements. The findings lay the groundwork for a new generation of terahertz scanners powered by artificial intelligence, intended for medical diagnostics, non-destructive testing, and security applications.

Keywords: single-pixel imaging, compressed sensing, neural networks